학사학위 논문

# 약물 안전성 예측 인공지능 모델 개발

박요한

전기전자컴퓨터공학부

Gwanju Institute of Science and Technology

2025

# 약물 안전성 예측 인공지능 모델 개발

# Development of an AI model for drug safety profile prediction

BS/EC 20195067 Park Yohan(박요한). Development of an AI model for drug safety profile prediction(약물 안전성 예측 인공지능 모델 개발). School of Electrical Engineering and Computer Science. 2025. 20p. Prof. Hojung Nam

**Abstract**

The evaluation of drug safety is based on a comprehensive analysis of ADMET properties, including Absorption, Distribution, Metabolism, Excretion, and Toxicity. Traditionally, confirming the ADMET properties of compounds requires in vivo and in vitro experiments, which are time-consuming and costly. To overcome these challenges, AI-based ADMET prediction models have gained significant attention.

In this study, a deep learning model was designed to predict 10 ADMET properties. Additional experiments were conducted on Scaffold split data to evaluate the generalization performance of the model. Furthermore, an ablation study was performed to analyze the effects of normalization and stabilization techniques applied to enhance model performance. Experimental results demonstrated that the proposed model outperformed the comparative model for most ADMET properties, although its generalization performance showed limitations under specific conditions.

This study highlights the importance of detailed model design customized to specific prediction targets for improving the accuracy of ADMET property predictions. Additionally, it emphasizes the necessity of exploring various approaches to overcome performance limitations. These findings contribute to the advancement of drug safety prediction models and their practical application in drug development environments.

BS/EC 20195067 Park Yohan(박요한). Development of an AI model for drug safety profile prediction(약물 안전성 예측 인공지능 모델 개발). School of Electrical Engineering and Computer Science. 2025. 20p. Prof. Hojung Nam

**국문요약**

약물의 안전성 평가는 흡수(Absorption), 분포(Distribution), 대사(Metabolism), 배설(Excretion), 그리고 독성(Toxicity)과 같은 ADMET 특성에 대한 종합적 분석을 기반으로 이루어진다. 전통적으로는 화합물의 ADMET 특성을 확인하기 위해 *in vivo* 및 *in vitro* 실험을 진행해야 하며, 이는 시간과 비용이 많이 소요되는 과제이다. 이를 극복하기 위해 인공지능 기반의 ADMET 특성 예측 모델이 주목받고 있다.

본 연구에서는 총 10개의 ADMET 특성을 예측하는 딥러닝 모델을 설계했다. 모델의 일반화 성능을 평가하기 위해 Scaffold split을 적용한 데이터에서 추가 실험을 진행했다. 또한, 모델의 성능을 높이기 위해 적용한 정규화 및 안정화 기법의 효과를 분석하기 위해, ablation study를 수행했다. 실험 결과, 제안된 모델은 대부분의 ADMET 특성에서 비교 모델보다 우수한 성능을 보였으나, 특정 조건에서 일반화 성능의 한계가 확인되었다.

본 연구는 ADMET 특성 예측의 정확도를 높이기 위해 예측 대상에 따른, 세부적인 모델 설계의 중요성을 제시했다. 또한, 성능 한계를 극복하기 위한 다양한 접근법의 필요성을 제시했다. 이는 향후 연구에서 약물 안전성 예측 모델의 개선과 신약 개발 환경에서의 실질적 활용 가능성을 높이는 데 기여할 수 있을 것이다.

# 목　　차

Abstract ····· i
국문요약 ····· ii
목　　차 ····· iii
표 목 차 ····· v
그림목차 ····· vi

I. 서　론 ····· 1

II. 문헌 및 이론 연구 ····· 2
2. 1. ADMET ····· 2
2. 1. 1. 흡수 ····· 2
2. 1. 2. 분포 ····· 3
2. 1. 3. 대사 ····· 3
2. 1. 4. 배설 ····· 4
2. 1. 5. 독성 ····· 4
2. 2. Scaffold 기반 데이터 분할 ····· 4
2. 3. Normalization and Regularization Techniques ····· 5
2. 3. 1. Batch Normalization ····· 5
2. 3. 2. Dropout ····· 5
2. 3. 3. Weight Decay ····· 6

Ⅲ. 연구 절차 및 방법 ····· 7
3. 1. 연구 데이터 ····· 7
3. 1. 1. 데이터 수집 및 전처리 ····· 7
3. 1. 2. 데이터 분할 ····· 7
3. 2. Model design ····· 8

3. 2. 1. MLP ····· 8
3. 2. 2. RF ····· 9
3. 3. Experiment Setup ····· 9
3. 4. Ablation Study ····· 10

Ⅳ. 결과 및 논의 ····· 11
4. 1. Proposed 모델과 Baseline 모델의 성능 비교 ····· 11
4. 2. Random split과 Scaffold split 성능 비교 ····· 11
4. 3. Ablation Study ····· 12

Ⅴ. 결　론 ····· 16
5. 1. Proposed 모델과 Baseline 모델의 성능 비교 ····· 16
5. 2. Random split과 Scaffold split 성능 비교 ····· 16
5. 3. Ablation Study ····· 16

참고문헌 ····· 18
Acknowledgment ····· 21

# 표 목 차

4. 1. Regression task에서 두 모델의 성능 ····· 11
4. 2. Classification task에서 두 모델의 성능 ····· 11
4. 3. Regression task에서 분할 방식에 따른 모델 성능 ····· 11
4. 4. Classification task에서 분할 방식에 따른 모델 성능 ····· 12
4. 5. Lipophilicity task에 대한 Ablation Study 결과 ····· 12
4. 6. Solubility task에 대한 Ablation Study 결과 ····· 12
4. 7. PPBR task에 대한 Ablation Study 결과 ····· 13
4. 8. BBB task에 대한 Ablation Study 결과 ····· 13
4. 9. CYP3A4 inhibitor task에 대한 Ablation Study 결과 ····· 13
4. 10. HLM task에 대한 Ablation Study 결과 ····· 13
4. 11. CLp task에 대한 Ablation Study 결과 ····· 14
4. 12. UGT substrate task에 대한 Ablation Study 결과 ····· 14
4. 13. hERG task에 대한 Ablation Study 결과 ····· 14
4. 14. LD50 task에 대한 Ablation Study 결과 ····· 14

# 그림목차

2. 1. ADMET 카테고리 및 소속 특성 ····· 2
3. 1. Random split and Scaffold split implementation ····· 8
3. 2. Model architecture ····· 8

# I. 서 론

신약 개발 과정에서 약물의 안전성을 확인하는 것은 매우 중요하고 필수적인 절차이다. 약물의 독성을 포함한 약동학적 프로파일을 분석하여, 약물의 안전성을 평가할 수 있다. 이러한 평가는 ADMET으로 알려진 5가지 주요 기준에 따라 이루어진다. 흡수(Absorption), 분포(Distribution), 대사(Metabolism), 배설(Excretion), 그리고 독성(Toxicity)에 대한 종합적인 분석을 통해 약물의 안전성을 평가할 수 있다.

ADMET 특성 분석은 신약 개발 과정에서 필수적이지만, 상당한 시간과 비용이 소모된다 [1]. 이를 해결하기 위해서 *in silico* 접근법이 효과적인 대안으로 주목받고 있으며, 최근 인공지능 기술의 발전과 함께 그 활용도가 더욱 높아지고 있다. 약물의 분자 구조 정보를 학습하여, 약동학적 특성을 예측하는 인공지능 모델에 대한 연구가 활발히 이루어지고 있다 [2]. 인공지능을 이용한 예측 모델은 아직 실험을 완전히 대체할 수준으로 발전하지는 않았지만, 후보군을 선별하거나, 연구자에게 유의미한 통찰을 제공해 줄 수 있다.

본 연구에서는 각 ADMET 카테고리별로 두 가지 endpoint를 선정하여, 총 10개의 single-task 딥러닝 예측 모델을 설계하고 학습했다. 이 모델은 4개의 회귀(regression) 작업과 6개의 분류(classification) 작업으로 구성되어 있으며, 입력 데이터로는 분자의 구조 정보를 나타내는 ECFP4를 사용하였다. 딥러닝 모델은 multi-layer perceptron(MLP) 구조를 기반으로 하며, 이를 통해 ADMET 예측 정확도를 분석하고자 한다.

본 연구에서 사용한 ADMET 데이터셋은 상대적으로 크기가 작으며, 이로 인해 모델이 학습 과정에서 과적합이 발생할 가능성이 크다. 제안한 ADMET 예측 MLP 모델의 일반화 성능을 높이기 위해 Batch Normalization, Dropout, Weight Decay와 같은 학습 안정화 및 정규화 효과를 가진 기법을 적용했다. 이러한 기법들의 효과를 검증하기 위해 Ablation Study를 진행했다. 각 기법을 제거한 상태 모델로 성능을 확인하여, 해당 기법들이 ADMET 예측 모델의 성능에 미치는 영향을 정량적으로 분석하였다.

추가적으로, 모델의 현실적인 활용 가능성을 평가하기 위해 Scaffold split을 적용한 실험을 수행하였다. Scaffold split은 분자 골격 구조의 유사성을 기준으로 데이터를 분리하여, 실제 신약 개발 환경에서 모델이 새로운 분자 골격 구조에 대해 얼마나 잘 일반화할 수 있는지를 평가하는 방법이다. 이는 Random split과 비교했을 때 성능이 낮아질 수 있지만, 현실적인 조건에서 모델의 신뢰성을 확보하기 위해 중요한 과정이다. 본 연구에서는 Scaffold split 실험을 통해 딥러닝 모델이 새로운 화학 구조를 얼마나 잘 예측할 수 있는지 평가하고, 이로부터 모델의 한계와 개선 가능성을 탐구하고자 한다.

# Ⅱ. 문헌 및 이론 연구

## 2. 1. ADMET

약물이 체내에서 효과를 나타내기 위해서는, 임의의 경로를 통해 약물이 투약되고, 순환계로 흡수되어, 원하는 작용 부위에 도달해야 하고, 이후 최종적으로는 분해되어 몸에서 배출되어야 한다. 이러한 일련의 과정이 이상적으로 이루어지지 않으면, 약물이 어떠한 효과도 발휘하지 못하거나, 예상치 못한 부작용이 일어날 수 있다. 약물의 이상적이지 못한 ADME 특성은 치료 실패의 중요한 요인이 된다. 따라서 약물 개발과정에서 ADME 특성을 빠르고 정확하게 찾는 것은 중요하다 [1].

ADME 특성의 분석은 약물의 흡수부터 배출까지의 과정에 대해 이해하고, 체내에 남아서 부작용이 일어날지 확인하기 위한 목적을 가진다. 독성 분석은 약물의 안전성을 직접적으로 평가하기 위해 이루어진다. 약물은 다양한 방식으로 다양한 장기와 조직에 손상을 줄 수 있기 때문에, 독성 평가로 안전성을 검증해야 한다.

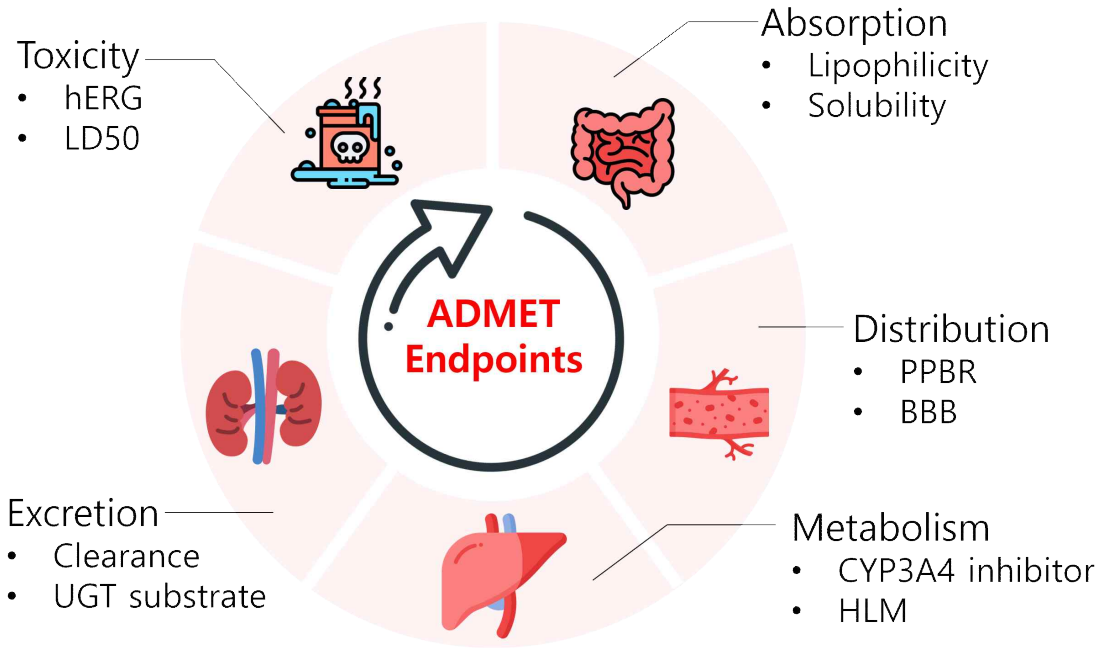


Figure 2. 1. ADMET 카테고리 및 소속 특성

### 2. 1. 1. 흡수

약물이 체내에서 이동하기 위해서는 순환계에 흡수되어야 한다. 경구 투약된 약물은 소화기관을 거치고, 주로 장 내 점막을 통해 흡수되어 순환계로 이동한다. 만약 약물이 장을 통한 흡수가 힘들다면, 정맥 투여 등의 방식을 고려할 수 있다.

Lipophilicity는 화합물이 지질 환경과 물 사이에서 얼마나 잘 분배되는지를 나타내는 척도이다. 높은 지용성은 생체막에 대한 높은 친화성을 나타낼 수 있지만, 과도한 경우 약물이 막 내부에 갇혀 낮은 흡수율과 낮은 생체이용률을 초래할 수 있다. 또한, 지용성이 높으면 대사 과정에서 약물이 빠르게 분해될 가능성이 있어, 약효가 발휘되기 전에 체내에서 제거될 위험이 존재한다 [3].

Solubility는 화합물이 물에 용해될 수 있는 최대량을 나타내는 척도로, 약물 설계와 개발에서 중요한 역할을 한다. 낮은 수용해도는 약물 스크리닝 과정에서 침전을 유발하여 결과의 신뢰성을 저하시킬 수 있으며, 이로 인해 개발 비용과 시간이 증가할 가능성이 있다 [4].

2. 1. 2. 분포

약물이 조직 사이에서 어떻게 이동하는지에 대한 분석과, 순환계에서 조직으로 얼마나 이동했는지에 대한 분석을 진행하여, 약물의 체내 분포에 대해 알 수 있다.

인간 Plasma Protein Binding Rate(PPBR)은 혈액 내에서 혈장 단백질에 결합된 약물의 비율을 의미한다. 결합된 비율이 낮을수록, 원하는 표적으로 더 효율적으로 이동할 수 있다 [5].

Blood-Brain Barrier(BBB)는 뇌혈관장벽을 투과할 수 있는지에 대한 여부를 확인하는 endpoint이다. 이 장벽은 뇌를 보호하기 위해, 세균이나 위험한 물질이 혈액에서 뇌로 이동하는 것을 막는 역할을 한다. 따라서 중추 신경계에 작용하는 약물을 개발하기 위해서는 BBB를 통과하는 성질을 갖는지 확인하는 것이 중요하다 [6].

2. 1. 3. 대사

약물은 체내에서 대사 효소 시스템에 의해 분해가 진행된다. 일부 약물은 분해를 통해 배설이 용이하게 바뀔 수도 있다. 일부 약물은 대사를 통해 활성을 잃을수도 있고, 대사산물이 약물로 작용할 수도 있다. 또한, 일부 경우에는 분해를 통해 생성된 대사산물이 중독을 유발할 수도 있다.

CYP450는 다양한 분자와 화합물의 대사, 특히 약물의 산화 및 변형에 관여하는 효소 초가족이다. 약물을 변형시켜 비활성화하거나 독성을 낮출 수 있지만, 이 효소의 작용을 억제하는 약물은 대사율을 감소시켜 약물의 체내 축적을 초래할 수 있다. 이러한 억제는 약물 간 상호작용을 유발하며, 부정적인 부작용을 증가시킬 가능성이 있다 [7].

HLM stability는 약물의 대사 안전성을 평가하는 중요한 약동학적 property다. 약물의 clearance, 반감기, 생체 이용률에 큰 영향을 준다고 알려져 있다 [8].

2. 1. 4. 배설

Drug Excretion은 소변, 담즙, 땀, 눈물, 대변 등의 다양한 배설 경로를 이용하여 약물을 신체에서 제거하는 것을 의미한다.

Clearance in plasma (CLp)는 특정 시간 동안 혈장에서 제거된 약물의 부피로 정의되며, 활성 약물이 체내에서 제거되는 속도를 측정하는 지표이다 [9].

UDP-glucuronosyltranferase(UGT)는 Phase II 대사 효소로, 약물 분자에 글루쿠론산을 결합하여 약물의 수용성을 증가시키고, 체내 배출을 촉진한다 [9].

2. 1. 5. 독성

독성을 평가하는 endpoint에는 크게 두 가지로 분류할 수 있다. 하나는 약물이 특정 장기나 조직에 영향을 주는지 판단하는 것이고, 나머지는 동물 실험을 통해 투약 시 나타나는 독성 반응에 대한 분석이다.

hERG(Human ether-a-go-go related gene)는 전압 의존성 이온 채널의 발현과 관련된 유전자다. 이 유전자에 의해 발현되는 채널은 심장의 전기적 활동을 조절하는데 중요한 역할을 한다. hERG 채널은 심장 활동전위에서 재분극 전류를 매개하며, 약물 분자가 이를 차단할 경우, QT 간격 연장, 심장 부정맥 및 심정지를 유발할 가능성이 있다 [10].

LD50(Lethal Dose 50%)은 특정 화합물이 실험 대상의 50%에 해당하는 개체수를 사망에 이르게 하는 용량으로, 체중 1kg당 화합물의 양으로 정의된다. 이번 연구에서는 Rat을 대상으로 경구 노출에 의한 독성 데이터를 활용했다 [11].

2. 2. Scaffold 기반 데이터 분할

보편적으로 인공지능을 학습할 때, Random split은 데이터 분배의 공정성을 확보하고, 모델 성능을 일반화하기 위한 기본적인 접근 방식이다. 그러나 약물 개발과 관련된 인공지능 연구에서는 Scaffold split라는 분할 방식을 통해 실제 약물 개발 시나리오와 유사한 환경에서 모델의 성능을 측정할 수 있다 [12].

Scaffold split는 주어진 데이터 세트에서 분자의 골격을 기준으로 그룹화한 뒤, Train set에 포함되지 않은 scaffold group만을 Test set에 포함시키는 데이터 분할 방식이다. 이 방식은 모델이 분자의 구조 정보를 학습하는 과정에서 scaffold의 영향을 확인할 수 있도록 하며, 학습에 사용하지 않은 scaffold에 대해 모델이 얼마나 잘 일반화할 수 있는지도 확인할 수 있게 한다.

본 연구에서 Scaffold split을 할 때 사용한 분자의 골격은 Bemis-Murcko scaffold

representation을 기준으로 정의하였다. Bemis-Murcko scaffold를 구하는 것은 화합물을 R-group, 링커, 그리고 고리 구조로 분해하는 것에서 시작한다. 분자에서 R-group을 제거하여 고리 구조와, 이를 연결하는 링커만 유지하여, 분자의 골격을 얻을 수 있다 [13].

### 2. 3. Normalization and Regularization Techniques

딥러닝에서 normalization과 regularization은 일반화 능력을 강화하고, 모델의 성능을 향상시키는 역할을 한다. 다양한 기법 중, Batch Normalization, Dropout, Weight Decay는 널리 알려지고 자주 사용되는 기술이다.

#### 2. 3. 1 Batch Normalization

배치 정규화는 내부 공변량 변화를 완화하기 위해서 제안된 기법이다. 이 과정은 3가지 단계로 진행된다.

- 입력으로 들어가는 미니배치의 평균과 분산을 계산한다. 이 때, $\mu_B$는 미니배치 데이터의 평균, $\sigma_B^2$는 분산을 의미한다.

$$\mu_B = \frac{1}{n}\sum_{i=1}^{n} x_i,\ \ \sigma_B^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu_B)^2$$

- 배치 내의 데이터를 평균 0, 분산 1이 되도록 정규화를 진행한다.

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$

- 학습 가능한 두 개의 파라미터$\gamma, \beta$를 추가하여 모델이 데이터의 스케일을 조정한다.

$$y_i = \gamma \hat{x}_i + \beta$$

이런 과정을 통해 정규화를 진행하여, 모델의 layer마다 입력 분포가 계속 변하는 문제를 완화한다. 이를 통해 학습 과정이 안정적이고 빠르게 진행되며, 더 큰 학습률을 사용할 수 있어 효율적인 학습이 가능해진다 [14].

#### 2. 3. 2. Dropout

Dropout은 신경망의 과적합을 방지하기 위해 널리 사용하는 기법이다. 학습 중에 확률적으로 일부 뉴런을 랜덤하게 0으로 설정하는 dropout을 진행하고, iteration마다 다시 dropout을 진행한다. 훈련이 끝나고, 평가 단계에서는 모든 뉴런을 사용한다.

Dropout은 훈련 과정에서 모델이 특정 뉴런에 과하게 의존하는 것을 막을 수 있다. 또한, 평가 단계에서 다시 모든 뉴런을 사용하는 것은, 서로 다른 모델을 사용하는 ensemble 효과를

낼 수 있다 [15].

2. 3. 3. Weight Decay

Weight Decay는 손실함수에 모델 가중치에 대한 패널티 항을 추가하는 regularization 기법이다. 이 기법은 가중치의 L2 norm을 손실 함수에 더해, 모델이 큰 가중치를 가지는 것을 억제한다. Weight Decay를 통해 가중치를 작게 유지하면, 모델의 복잡도가 줄어들고, 과적합을 방지할 수 있다 [16].

# Ⅲ. 연구 절차 및 방법

## 3. 1. 연구 데이터

### 3. 1. 1. 데이터 수집 및 전처리

본 연구에서는 ADMET 분류에서 각 데이터의 개수가 많은 Endpoint를 선정하여 분석하였다. 이는 딥러닝(DL) 모델이 데이터 개수가 적을 경우 전통적인 머신러닝(ML)보다 성능이 저하될 가능성이 크기 때문이다. 선정된 Endpoint는 다음과 같다.

- 흡수(Absorption)와 관련된 지표로는 지용성(Lipophilicity, 회귀)과 용해도(Solubility, 회귀)가 각각 12,798개와 11,976개의 데이터로 선정되었다.
- 분포(Distribution) 영역에서는 혈장 단백질 결합률(PPBR, 회귀)과 혈뇌장벽 투과성(BBB, 분류)이 각각 4,987개와 4,042개의 데이터를 포함한다.
- 대사(Metabolism) 항목에서는 CYP3A4 저해제(CYP3A4 inhibitor, 분류)와 인간 간 미세소체 안전성(HLM, 분류)가 각각 25,605개와 6,009개의 데이터를 보유한다.
- 배설(Excretion) 관련 Task로는 혈장 제거율(CLp, 분류)과 UGT 기질(UGT substrate, 분류)이 각각 1,345개와 1,248개의 데이터를 기반으로 선정되었다.
- 독성(Toxicity) 지표로는 hERG 저해제(hERG, 분류)와 반수 치사량(LD50, 회귀)이 각각 14,287개와 10,610개의 데이터를 포함하고 있다.

데이터는 주로 TDC(Therapeutics Data Commons)와 Deep-PK라는 오픈 소스 플랫폼에서 수집되었고, 배설 카테고리의 CLp [17] 와 UGT substrate [18] 의 데이터는 각각 관련 문헌에서 확보했다.

모든 분자 데이터는 SMILES string 형태로 수집되었고, RDkit 라이브러리를 사용하여 canonical form으로 변환했다. 이 과정에서 invalid molecule로 확인된 데이터는 학습에 사용하지 않았다. 분자 데이터를 학습에 사용하기 위해서 Morgan fingerprint로 변환하는 과정을 수행했다. 변환 과정에서는 탐색 반경은 2로 설정하고, 출력 벡터의 차원은 1024로 지정했다.

### 3. 1. 2. 데이터 분할

모델 학습에 Random split 방식을 적용할 때, 데이터셋을 먼저 Train과 Test 세트로 9:1 비율로 나누었다. 이후 Train 세트를 활용해 5-fold 교차 검증(cross-validation)을 수행했다. 이렇게 얻어진 5개의 서로 다른 모델을 Test 세트를 이용해 검증한 후, 그 평균 성능을 모델의 최종 평가 지표로 사용했다.

Scaffold split 방식의 경우에도 마찬가지로 Train과 Test 세트를 9:1 비율로 나누었다.

Scaffold split 방식은 Train/Validation/Test set를 분자 골격을 기준으로 나누기 때문에, 데이터가 고르게 분배되지 않아 일반적으로 K-fold 교차 검증이 불가능하다. 따라서, Train 세트를 5번 shuffle한 뒤, 각 shuffle에서 Train/Validation 세트를 4:1 비율로 나누어 학습을 진행했다. 이렇게 생성된 5개의 서로 다른 Train/Validation 조합으로 학습된 모델을 Test 세트로 검증하였고, 그 평균 성능을 모델의 최종 평가 지표로 삼았다.

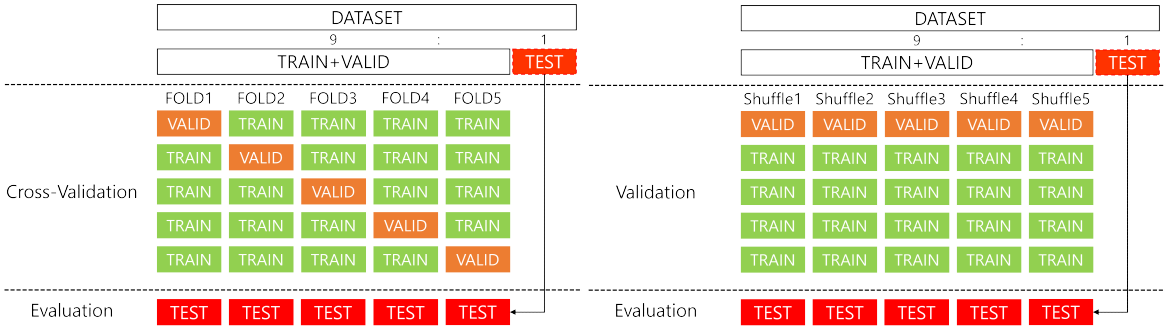


Figure 3. 1. Random split and Scaffold split implementation

3. 2. Model design

약물의 안전성 평가를 위해, 선택된 physicochemical property를 예측하는 10개의 딥러닝 모델을 설계했다. 각 모델은 동일한 기본 구조를 공유하되, 예측 과제(task)에 따라 하이퍼파라미터를 개별적으로 조정하였다. 또한, 딥러닝 모델의 상대적 성능을 확인하기 위해서 Random Forest(RF) 모델을 비교 모델로 사용했다.

3. 2. 1. MLP

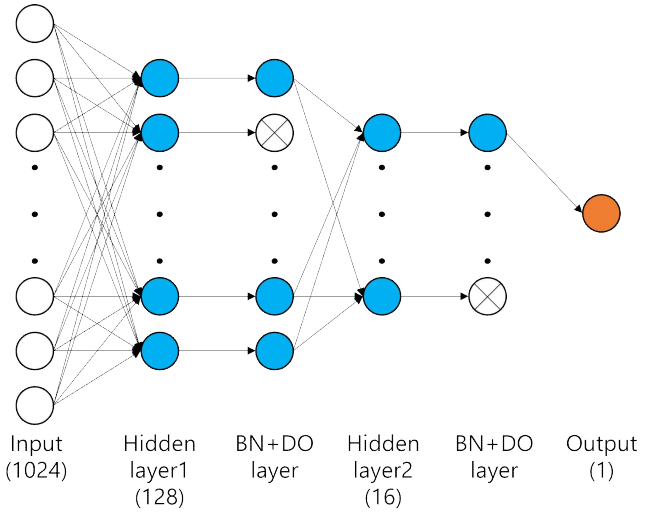


Figure 3. 2. Model architecture

약물의 physicochemical property를 예측하는 딥러닝 모델은 Multi Layer Perceptron(MLP) 기반으로 설계되었다. 모델은 3개의 선형 계층(linear layer)로 구성되며, 차원은 1024에서 128, 16, 최종적으로 1로 점진적으로 축소하며 고차원의 분자 특성을 학습하도록 설계했다. 첫 번째와 두 번째 계층에는 Batch Normalization과 Dropout이 적용되었으며, 계층 간 활성화 함수로는 ReLU를 사용했다. 모든 가중치는 He 초기화 방식을 따랐으며, Bias는 0으로 초기화했다.

모델 최적화를 위해 각 task별로 하이퍼파라미터 튜닝을 Random split을 기준으로 진행하였다. 하이퍼파라미터 조합은 다음과 같으며, Grid Search를 통해 최적값을 탐색하였다.

하이퍼파라미터 조합:

- Learning Rate(lr): [1e-4, 1e-3, 1e-2]
- Weight Decay: [1e-4, 1e-3, 1e-2]
- Dropout Rate: [0.0, 0.1, 0.2, 0.3]

3. 2. 2. RF

비교 모델로 사용된 RF는 앙상블 학습 기반의 비선형 모델로 데이터의 양이 적거나 해석성이 요구되는 경우 널리 사용된다. 본 연구에서는 다음과 같은 하이퍼파리미터 조합에서 task별로 튜닝을 진행했다. Random search를 통해 최적의 하이퍼파라미터를 탐색하였으며, 각 모델별로 80회의 탐색을 수행했다.

하이퍼파라미터 조합:

- n_estimators: [100, 300, 500, 700]
- max_features: range(20, 101, 5)
  (20에서 100까지, 5씩 증가)
- min_samples_split: range(2, 9, 2)
  (2에서 8까지, 2씩 증가)

3. 3. Experiment Setup

MLP 모델 학습에는 ADAM Optimizer를 사용하였으며, Overfitting을 방지하기 위해 Weight Decay를 적용하였다. 또한, 교차검증 과정에서는 각 validation set의 성능을 모니터링하여 validation loss가 10 epoch 동안 개선되지 않을 경우 학습을 중단하는 방식으로 Early Stopping 기법을 적용하였다.

모든 하이퍼파라미터 튜닝 과정은 Train 세트에서만 수행하였으며, 5-fold Cross

Validation을 통해 일반화된 성능을 기준으로 최적 조합을 선정하였다. Regression task의 경우에는 $R^2$을 기준으로, Classification task는 ROC AUC를 기준으로 best 모델을 선정했다.

### 3. 4. Ablation Study

Random split된 데이터를 이용해 학습된 MLP 모델을 대상으로 Ablation Study를 수행했다. 이 연구는 모델의 과적합을 방지하고 성능을 향상시키기 위해 적용된 세 가지 기법 (Batch normalization, Drop out, 그리고 Weight Decay)의 개별적인 효과를 평가하는 데 초점을 맞추었다. Ablation Study에서는 각 기법을 개별적으로 제거하거나 조합하여 적용함으로써, 해당 기법들이 모델 성능에 미치는 영향을 정량적으로 분석했다.

# Ⅳ. 결과 및 논의

## 4. 1. Proposed 모델과 Baseline 모델의 성능 비교

| | | R^2 | PCC | MSE | RMSE | MAE |
|---|---|---|---|---|---|---|
| Lipophilicity | RF | 0.6848±0.0058 | 0.8486±0.0040 | 0.6237±0.0115 | 0.7897±0.0073 | 0.5871±0.0040 |
| | MLP | **0.7515±0.0141** | **0.8682±0.0073** | **0.4916±0.0279** | **0.7009±0.0198** | **0.5152±0.0104** |
| Solubility | RF | 0.6584±0.0028 | 0.8160±0.0021 | 1.8119±0.0150 | 1.3460±0.0056 | 0.9592±0.0032 |
| | MLP | **0.6920±0.0036** | **0.8337±0.0026** | **1.6341±0.0193** | **1.2783±0.0075** | **0.9168±0.0069** |
| PPBR | RF | 0.5375±0.0136 | 0.7513±0.0122 | 355.6372±10.4733 | 18.8563±0.2769 | 12.9393±0.2318 |
| | MLP | **0.5912±0.0247** | **0.7725±0.0141** | **314.3589±19.0119** | **17.7221±0.5358** | **11.5732±0.4411** |
| LD50 | RF | **0.6196±0.0072** | **0.7903±0.0050** | **0.3299±0.0063** | **0.5744±0.0054** | **0.4110±0.0024** |
| | MLP | 0.5626±0.0187 | 0.7539±0.0127 | 0.3794±0.0162 | 0.6158±0.0131 | 0.4564±0.0079 |

Table 4. 1. Regression task에서 두 모델의 성능

| | | ROC AUC | PR AUC | ACC | Precision | Recall | F1 |
|---|---|---|---|---|---|---|---|
| BBB | RF | 0.9844±0.0009 | 0.9932±0.0005 | 0.9486±0.0030 | 0.9427±0.0026 | **0.9891±0.0032** | 0.9653±0.0020 |
| | MLP | **0.9885±0.0039** | **0.9951±0.0017** | **0.9640±0.0084** | **0.9744±0.0084** | 0.9750±0.0070 | **0.9747±0.0059** |
| CYP3A4 inhibitor | RF | 0.8907±0.0023 | 0.8513±0.0025 | 0.8128±0.0031 | 0.7826±0.0048 | **0.7604±0.0279** | **0.7700±0.0077** |
| | MLP | **0.8909±0.0028** | **0.8531±0.0039** | **0.8219±0.0048** | **0.8319±0.0048** | 0.6424±0.0073 | 0.7249±0.0054 |
| HLM | RF | **0.8513±0.0038** | 0.7642±0.0031 | **0.8078±0.0037** | **0.8076±0.0073** | 0.5822±0.0137 | 0.6765±0.0088 |
| | MLP | 0.8458±0.0054 | **0.7676±0.0058** | 0.7903±0.0053 | 0.7073±0.0053 | **0.6882±0.0110** | **0.6972±0.0119** |
| CLp | RF | **0.7616±0.0229** | 0.7058±0.0231 | **0.6825±0.0117** | **0.6639±0.0169** | 0.6432±0.0241 | 0.6530±0.0135 |
| | MLP | 0.7288±0.0254 | **0.7146±0.0365** | 0.6637±0.0173 | 0.6638±0.0173 | **0.6853±0.0343** | **0.6723±0.0065** |
| UGT substrate | RF | **0.8833±0.0060** | 0.8957±0.0021 | **0.8200±0.0124** | 0.8408±0.0197 | **0.8462±0.0117** | **0.8433±0.0093** |
| | MLP | 0.8789±0.0036 | **0.9213±0.0056** | 0.8016±0.0078 | **0.8437±0.0078** | 0.8000±0.0206 | 0.8208±0.0065 |
| hERG | RF | **0.9151±0.0021** | **0.9385±0.0016** | 0.8346±0.0048 | 0.8371±0.0053 | **0.8953±0.0061** | 0.8652±0.0038 |
| | MLP | 0.9035±0.0024 | 0.9224±0.0037 | **0.8403±0.0039** | **0.8696±0.0039** | 0.8643±0.0109 | **0.8668±0.0032** |

Table 4. 2. Classification task에서 두 모델의 성능

본 연구에서는 ADMET 특성 예측을 위해 MLP 모델을 개발하고, 이를 비교 모델인 RF와 성능 비교를 수행하였다. 실험 결과, MLP는 대부분의 특성에서 제시된 성능 지표에서 RF 대비 우위가 관찰되었다.

일부 특성에서는 RF가 딥러닝 모델과 비슷하거나 더 나은 성능을 보였다. HLM, UGT substrate, hERG에서는 두 모델이 비슷한 성능을, LD50, CLp에서는 RF가 상대적으로 좋은 성능을 보인다.

## 4. 2. Random split과 Scaffold split 성능 비교

| | Split | R^2 | PCC | MSE | RMSE | MAE |
|---|---|---|---|---|---|---|
| Lipophilicity | Random | **0.7515±0.0141** | **0.8682±0.0073** | **0.4916±0.0279** | **0.7009±0.0198** | **0.5152±0.0104** |
| | Scaffold | 0.4567±0.0067 | 0.6891±0.0050 | 0.9196±0.0114 | 0.9589±0.0059 | 0.7284±0.0057 |
| Solubility | Random | **0.6920±0.0036** | **0.8337±0.0026** | **1.6341±0.0193** | **1.2783±0.0075** | **0.9168±0.0069** |
| | Scaffold | 0.1684±0.0265 | 0.5589±0.0067 | 4.0480±0.1289 | 2.0117±0.0321 | 1.5600±0.0310 |
| PPBR | Random | **0.5912±0.0247** | **0.7725±0.0141** | **314.3589±19.0119** | **17.7221±0.5358** | **11.5732±0.4411** |
| | Scaffold | 0.2806±0.0371 | 0.5694±0.0201 | 426.5260±21.9766 | 20.6458±0.5260 | 14.0361±0.3285 |
| LD50 | Random | **0.5626±0.0187** | **0.7539±0.0127** | **0.3794±0.0162** | **0.6158±0.0131** | **0.4564±0.0079** |
| | Scaffold | 0.0086±0.0405 | 0.3627±0.0186 | 0.6667±0.0272 | 0.8163±0.0166 | 0.5852±0.0137 |

Table 4. 3. Regression task에서 분할 방식에 따른 모델 성능

| | Split | ROC AUC | PR AUC | ACC | Precision | Recall | F1 |
|---|---|---|---|---|---|---|---|
| BBB | Random | **0.9885±0.0039** | **0.9951±0.0017** | **0.9640±0.0084** | **0.9744±0.0084** | **0.9750±0.0070** | **0.9747±0.0059** |
| | Scaffold | 0.8820±0.0043 | 0.9038±0.0089 | 0.8306±0.0073 | 0.8070±0.0092 | 0.9526±0.0089 | 0.8737±0.0048 |
| CYP3A4 inhibitor | Random | **0.8909±0.0028** | **0.8531±0.0039** | **0.8219±0.0048** | **0.8319±0.0048** | **0.6424±0.0073** | **0.7249±0.0054** |
| | Scaffold | 0.7309±0.0019 | 0.7068±0.0039 | 0.6655±0.0025 | 0.6879±0.0123 | 0.5498±0.0178 | 0.6107±0.0063 |
| HLM | Random | **0.8458±0.0054** | **0.7676±0.0058** | **0.7903±0.0053** | **0.7073±0.0053** | **0.6882±0.0110** | **0.6972±0.0119** |
| | Scaffold | 0.7753±0.0040 | 0.6492±0.0034 | 0.7424±0.0048 | 0.6659±0.0082 | 0.6205±0.0189 | 0.6422±0.0098 |
| CLp | Random | **0.7288±0.0254** | **0.7146±0.0365** | **0.6637±0.0173** | **0.6638±0.0173** | **0.6853±0.0343** | **0.6723±0.0065** |
| | Scaffold | 0.6265±0.0237 | 0.5879±0.0327 | 0.5970±0.0160 | 0.6046±0.0342 | 0.5303±0.0748 | 0.5602±0.0317 |
| UGT substrate | Random | **0.8789±0.0036** | **0.9213±0.0056** | **0.8016±0.0078** | **0.8437±0.0078** | **0.8000±0.0206** | **0.8208±0.0065** |
| | Scaffold | 0.7874±0.0124 | 0.7581±0.0156 | 0.7264±0.0060 | 0.7126±0.0146 | 0.7683±0.0342 | 0.7387±0.0104 |
| hERG | Random | **0.9035±0.0024** | **0.9224±0.0037** | **0.8403±0.0039** | **0.8696±0.0039** | **0.8643±0.0109** | **0.8668±0.0032** |
| | Scaffold | 0.7425±0.0051 | 0.7577±0.0066 | 0.6829±0.0049 | 0.6846±0.0079 | 0.7690±0.0105 | 0.7243±0.0027 |

Table 4. 4. Classification task에서 분할 방식에 따른 모델 성능

본 연구에서 제안한 MLP 모델로 각각 Random split 데이터와 Scaffold split 데이터로 학습 및 평가를 진행했다. Scaffold split dataset으로 학습했을 때, 모든 특성에서 예측 성능의 감소가 관찰되었다. 이는 Scaffold split은 Random split보다 일반화 성능을 더 엄격하게 검증하기 위해 사용했기에, 예상할 수 있는 결과이다. 성능이 떨어지긴 했지만, 대부분의 Task에서 안정적인 성능을 유지하는 것을 보였다. 하지만, Solubility와 LD50과 같이 특정 Task에서 성능 하락폭이 상대적으로 큰 것을 확인할 수 있다.

## 4. 3. Ablation Study

| | Lipophilicity(reg) | | | | |
|---|---|---|---|---|---|
| | R^2 | PCC | MSE | RMSE | MAE |
| Baseline | 0.7515±0.0141 | 0.8682±0.0073 | 0.4916±0.0279 | 0.7009±0.0198 | 0.5152±0.0104 |
| -BN | 0.7540±0.0070 | **0.8692±0.0045** | 0.4867±0.0139 | 0.6976±0.0099 | 0.5088±0.0076 |
| -Dropout | 0.7502±0.0103 | 0.8681±0.0047 | 0.4942±0.0204 | 0.7028±0.0144 | 0.5122±0.0094 |
| -WD | 0.7494±0.0094 | 0.8664±0.0047 | 0.4959±0.0187 | 0.7041±0.0132 | 0.5119±0.0081 |
| -BN, -Dropout | 0.7416±0.0110 | 0.8625±0.0058 | 0.5112±0.0218 | 0.7148±0.0154 | 0.5221±0.0113 |
| -BN, -WD | **0.7547±0.0079** | 0.8691±0.0048 | **0.4854±0.0156** | **0.6966±0.0111** | **0.5010±0.0019** |
| -Dropout, -WD | 0.7466±0.0105 | 0.8642±0.0061 | 0.5014±0.0208 | 0.7079±0.0146 | 0.5108±0.0089 |
| None | 0.7472±0.0124 | 0.8648±0.0071 | 0.5001±0.0245 | 0.7070±0.0173 | 0.5084±0.0102 |

Table 4. 5. Lipophilicity task에 대한 Ablation Study 결과

| | Solubility(reg) | | | | |
|---|---|---|---|---|---|
| | R^2 | PCC | MSE | RMSE | MAE |
| Baseline | **0.6920±0.0036** | **0.8337±0.0026** | **1.6341±0.0193** | **1.2783±0.0075** | 0.9168±0.0069 |
| -BN | 0.6906±0.0095 | 0.8319±0.0051 | 1.6412±0.0504 | 1.2810±0.0197 | **0.9164±0.0114** |
| -Dropout | 0.6778±0.0076 | 0.8275±0.0040 | 1.7092±0.0402 | 1.3073±0.0153 | 0.9333±0.0186 |
| -WD | 0.6859±0.0076 | 0.8309±0.0032 | 1.6663±0.0403 | 1.2908±0.0156 | 0.9239±0.0106 |
| -BN, -Dropout | 0.6770±0.0054 | 0.8279±0.0028 | 1.7132±0.0286 | 1.3089±0.0109 | 0.9334±0.0093 |
| -BN, -WD | 0.6813±0.0077 | 0.8263±0.0042 | 1.6908±0.0408 | 1.3002±0.0157 | 0.9315±0.0067 |
| -Dropout, -WD | 0.6738±0.0053 | 0.8246±0.0025 | 1.7303±0.0280 | 1.3154±0.0106 | 0.9370±0.0088 |
| None | 0.6751±0.0045 | 0.8271±0.0032 | 1.7236±0.0237 | 1.3128±0.0091 | 0.9327±0.0069 |

Table 4. 6. Solubility task에 대한 Ablation Study 결과

| | PPBR(reg) | | | | |
|---|---|---|---|---|---|
| | R^2 | PCC | MSE | RMSE | MAE |
| Baseline | 0.5912±0.0247 | 0.7725±0.0141 | 314.3589±19.0119 | 17.7221±0.5358 | 11.5732±0.4411 |
| -BN | 0.4974±0.0223 | 0.7174±0.0122 | 386.4422±17.1316 | 19.6534±0.4334 | 14.6884±0.5966 |
| -Dropout | **0.6029±0.0176** | **0.7797±0.0105** | **305.3605±13.5721** | **17.4702±0.3887** | **11.5081±0.4340** |
| -WD | 0.5886±0.0215 | 0.7724±0.0105 | 316.3740±16.5184 | 17.7808±0.4670 | 11.5715±0.3854 |
| -BN, -Dropout | 0.4647±0.0189 | 0.7126±0.0098 | 411.5896±14.5278 | 20.2845±0.3569 | 15.0581±0.1634 |
| -BN, -WD | 0.4972±0.0196 | 0.7164±0.0102 | 386.6170±15.1046 | 19.6588±0.3838 | 14.7433±0.3522 |
| -Dropout, -WD | 0.5924±0.0240 | 0.7744±0.0152 | 313.3989±18.4760 | 17.6954±0.5211 | 11.5625±0.3899 |
| None | 0.4682±0.0428 | 0.7156±0.0213 | 408.9537±32.8922 | 20.2060±0.8187 | 14.9471±0.6828 |

Table 4. 7. PPBR task에 대한 Ablation Study 결과

| | BBB(cls) | | | | | |
|---|---|---|---|---|---|---|
| | ROC AUC | PR AUC | ACC | Precision | Recall | F1 |
| Baseline | 0.9885±0.0039 | 0.9951±0.0017 | **0.9640±0.0084** | 0.9744±0.0084 | 0.9750±0.0070 | **0.9747±0.0059** |
| -BN | 0.9888±0.0029 | 0.9946±0.0019 | 0.9516±0.0040 | **0.9794±0.0040** | 0.9521±0.0070 | 0.9655±0.0029 |
| -Dropout | 0.9892±0.0034 | 0.9951±0.0017 | 0.9575±0.0121 | 0.9710±0.0121 | 0.9694±0.0115 | 0.9700±0.0089 |
| -WD | **0.9899±0.0043** | **0.9954±0.0022** | 0.9635±0.0042 | 0.9737±0.0042 | **0.9750±0.0044** | 0.9743±0.0031 |
| -BN, -Dropout | 0.9881±0.0038 | 0.9952±0.0016 | 0.9565±0.0084 | 0.9801±0.0084 | 0.9583±0.0056 | 0.9691±0.0061 |
| -BN, -WD | 0.9816±0.0023 | 0.9887±0.0022 | 0.9536±0.0085 | 0.9695±0.0085 | 0.9653±0.0095 | 0.9672±0.0062 |
| -Dropout, -WD | 0.9875±0.0039 | 0.9943±0.0021 | 0.9600±0.0088 | 0.9755±0.0088 | 0.9681±0.0058 | 0.9718±0.0062 |
| None | 0.9874±0.0039 | 0.9938±0.0028 | 0.9580±0.0056 | 0.9735±0.0056 | 0.9674±0.0039 | 0.9704±0.0041 |

Table 4. 8. BBB task에 대한 Ablation Study 결과

| | CYP3A4 inhibitor(cls) | | | | | |
|---|---|---|---|---|---|---|
| | ROC AUC | PR AUC | ACC | Precision | Recall | F1 |
| Baseline | **0.8909±0.0028** | **0.8531±0.0039** | **0.8219±0.0048** | 0.7826±0.0048 | **0.7604±0.0279** | **0.7700±0.0077** |
| -BN | 0.8879±0.0021 | 0.8500±0.0019 | 0.8184±0.0019 | **0.8049±0.0019** | 0.7099±0.0132 | 0.7540±0.0073 |
| -Dropout | 0.8738±0.0044 | 0.8238±0.0052 | 0.8104±0.0030 | 0.7775±0.0030 | 0.7260±0.0182 | 0.7500±0.0089 |
| -WD | 0.8834±0.0014 | 0.8475±0.0008 | 0.8154±0.0048 | 0.7826±0.0048 | 0.7355±0.0212 | 0.7574±0.0102 |
| -BN, -Dropout | 0.8876±0.0019 | 0.8513±0.0027 | 0.8223±0.0034 | 0.8042±0.0034 | 0.7238±0.0078 | 0.7617±0.0074 |
| -BN, -WD | 0.8846±0.0019 | 0.8503±0.0021 | 0.8185±0.0045 | 0.7977±0.0045 | 0.7208±0.0113 | 0.7570±0.0091 |
| -Dropout, -WD | 0.8744±0.0022 | 0.8286±0.0036 | 0.8159±0.0068 | 0.7970±0.0068 | 0.7130±0.0137 | 0.7523±0.0114 |
| None | 0.8834±0.0012 | 0.8469±0.0016 | 0.8208±0.0045 | 0.8009±0.0045 | 0.7234±0.0116 | 0.7601±0.0053 |

Table 4. 9. CYP3A4 inhibitor task에 대한 Ablation Study 결과

| | HLM(cls) | | | | | |
|---|---|---|---|---|---|---|
| | ROC AUC | PR AUC | ACC | Precision | Recall | F1 |
| Baseline | **0.8458±0.0054** | **0.7676±0.0058** | **0.7903±0.0053** | 0.7073±0.0053 | **0.6882±0.0110** | **0.6972±0.0119** |
| -BN | 0.8438±0.0046 | 0.7582±0.0048 | 0.7903±0.0084 | **0.7200±0.0084** | 0.6597±0.0155 | 0.6884±0.0127 |
| -Dropout | 0.8331±0.0030 | 0.7514±0.0064 | 0.7784±0.0039 | 0.6968±0.0039 | 0.6531±0.0047 | 0.6740±0.0113 |
| -WD | 0.8446±0.0057 | 0.7652±0.0061 | 0.7903±0.0032 | 0.7087±0.0032 | 0.6844±0.0054 | 0.6961±0.0100 |
| -BN, -Dropout | 0.8394±0.0045 | 0.7516±0.0072 | 0.7830±0.0044 | 0.7054±0.0044 | 0.6569±0.0128 | 0.6800±0.0070 |
| -BN, -WD | 0.8419±0.0052 | 0.7538±0.0048 | 0.7880±0.0074 | 0.7135±0.0074 | 0.6626±0.0141 | 0.6869±0.0110 |
| -Dropout, -WD | 0.8336±0.0031 | 0.7517±0.0069 | 0.7787±0.0087 | 0.6953±0.0087 | 0.6578±0.0090 | 0.6758±0.0174 |
| None | 0.8384±0.0055 | 0.7498±0.0079 | 0.7874±0.0039 | 0.7078±0.0039 | 0.6730±0.0144 | 0.6896±0.0059 |

Table 4. 10. HLM task에 대한 Ablation Study 결과

| | CLp(cls) | | | | | |
|---|---|---|---|---|---|---|
| | ROC AUC | PR AUC | ACC | Precision | Recall | F1 |
| Baseline | 0.7288±0.0254 | 0.7146±0.0365 | 0.6637±0.0173 | 0.6638±0.0173 | 0.6853±0.0343 | 0.6723±0.0065 |
| -BN | 0.7437±0.0101 | 0.7411±0.0239 | 0.6844±0.0036 | 0.6952±0.0036 | 0.6676±0.0134 | 0.6801±0.0145 |
| -Dropout | 0.7288±0.0254 | 0.7146±0.0365 | 0.6637±0.0173 | 0.6638±0.0173 | 0.6853±0.0343 | 0.6723±0.0065 |
| -WD | 0.7276±0.0136 | 0.7113±0.0119 | 0.6474±0.0153 | 0.6547±0.0153 | 0.6353±0.0145 | 0.6444±0.0206 |
| -BN, -Dropout | 0.7437±0.0101 | **0.7411±0.0239** | **0.6844±0.0036** | 0.6952±0.0036 | **0.6676±0.0134** | **0.6801±0.0145** |
| -BN, -WD | 0.7438±0.0133 | 0.7402±0.0227 | 0.6844±0.0179 | 0.7063±0.0179 | 0.6412±0.0177 | 0.6707±0.0292 |
| -Dropout, -WD | 0.7276±0.0136 | 0.7113±0.0119 | 0.6474±0.0153 | 0.6547±0.0153 | 0.6353±0.0145 | 0.6444±0.0206 |
| None | **0.7438±0.0133** | 0.7402±0.0227 | 0.6844±0.0179 | **0.7063±0.0179** | 0.6412±0.0177 | 0.6707±0.0292 |

Table 4. 11. CLp task에 대한 Ablation Study 결과

CLp 특성을 예측하는 모델의 하이퍼파라미터 튜닝을 진행할 때, Dropout rate가 0인 조합이 최적의 성능을 보였다. 이에 따라 실제로 Baseline 모델에서도 Dropout이 제거된 상태로 실험이 진행되었다. 다른 Task와의 통일성을 위해 항목은 그대로 결과 표에 포함했다.

| | UGT substrate(cls) | | | | | |
|---|---|---|---|---|---|---|
| | ROC AUC | PR AUC | ACC | Precision | Recall | F1 |
| Baseline | **0.8789±0.0036** | **0.9213±0.0056** | **0.8016±0.0078** | 0.8437±0.0078 | **0.8000±0.0206** | **0.8208±0.0065** |
| -BN | 0.8584±0.0080 | 0.9119±0.0067 | 0.7936±0.0185 | **0.8452±0.0185** | 0.7803±0.0259 | 0.8112±0.0155 |
| -Dropout | 0.8674±0.0035 | 0.9120±0.0021 | 0.7984±0.0185 | 0.8419±0.0185 | 0.7972±0.0280 | 0.8173±0.0217 |
| -WD | 0.8687±0.0065 | 0.9173±0.0047 | 0.7840±0.0113 | 0.8193±0.0113 | 0.7972±0.0230 | 0.8072±0.0120 |
| -BN, -Dropout | 0.8598±0.0103 | 0.9126±0.0101 | 0.7888±0.0180 | 0.8396±0.0180 | 0.7775±0.0263 | 0.8072±0.0145 |
| -BN, -WD | 0.8466±0.0106 | 0.9056±0.0096 | 0.7936±0.0279 | 0.8434±0.0279 | 0.7831±0.0350 | 0.8119±0.0239 |
| -Dropout, -WD | 0.8533±0.0046 | 0.9051±0.0041 | 0.7680±0.0221 | 0.8130±0.0221 | 0.7718±0.0348 | 0.7905±0.0205 |
| None | 0.8432±0.0090 | 0.9023±0.0088 | 0.7872±0.0165 | 0.8431±0.0165 | 0.7690±0.0237 | 0.8042±0.0134 |

Table 4. 12. UGT substrate task에 대한 Ablation Study 결과

| | hERG(cls) | | | | | |
|---|---|---|---|---|---|---|
| | ROC AUC | PR AUC | ACC | Precision | Recall | F1 |
| Baseline | 0.9035±0.0024 | 0.9224±0.0037 | **0.8403±0.0039** | **0.8696±0.0039** | 0.8643±0.0109 | **0.8668±0.0032** |
| -BN | 0.9026±0.0026 | 0.9303±0.0026 | 0.8332±0.0017 | 0.8480±0.0017 | 0.8808±0.0108 | 0.8638±0.0034 |
| -Dropout | 0.8961±0.0049 | 0.9048±0.0064 | 0.8376±0.0038 | 0.8675±0.0038 | 0.8615±0.0027 | 0.8645±0.0037 |
| -WD | 0.8992±0.0015 | 0.9232±0.0021 | 0.8286±0.0031 | 0.8564±0.0031 | 0.8589±0.0050 | 0.8576±0.0029 |
| -BN, -Dropout | **0.9046±0.0023** | **0.9301±0.0023** | 0.8364±0.0044 | 0.8520±0.0044 | **0.8810±0.0056** | 0.8662±0.0048 |
| -BN, -WD | 0.8968±0.0009 | 0.9251±0.0014 | 0.8309±0.0015 | 0.8474±0.0015 | 0.8768±0.0075 | 0.8618±0.0014 |
| -Dropout, -WD | 0.8933±0.0035 | 0.9109±0.0055 | 0.8322±0.0065 | 0.8595±0.0065 | 0.8617±0.0027 | 0.8606±0.0061 |
| None | 0.8954±0.0018 | 0.9233±0.0022 | 0.8311±0.0013 | 0.8516±0.0013 | 0.8708±0.0019 | 0.8611±0.0010 |

Table 4. 13. hERG task에 대한 Ablation Study 결과

| | LD50(reg) | | | | |
|---|---|---|---|---|---|
| | R^2 | PCC | MSE | RMSE | MAE |
| Baseline | 0.5626±0.0187 | 0.7539±0.0127 | 0.3794±0.0162 | 0.6158±0.0131 | 0.4564±0.0079 |
| -BN | 0.5735±0.0084 | 0.7590±0.0060 | 0.3700±0.0073 | 0.6082±0.0060 | 0.4490±0.0065 |
| -Dropout | 0.5429±0.0086 | 0.7496±0.0049 | 0.3965±0.0075 | 0.6297±0.0059 | 0.4669±0.0071 |
| -WD | 0.5693±0.0183 | 0.7578±0.0107 | 0.3736±0.0159 | 0.6111±0.0128 | 0.4467±0.0103 |
| -BN, -Dropout | 0.5439±0.0051 | 0.7441±0.0047 | 0.3957±0.0044 | 0.6290±0.0035 | 0.4665±0.0012 |
| -BN, -WD | **0.5765±0.0122** | **0.7599±0.0081** | **0.3674±0.0106** | **0.6061±0.0088** | **0.4417±0.0069** |
| -Dropout, -WD | 0.5499±0.0156 | 0.7486±0.0075 | 0.3904±0.0135 | 0.6247±0.0108 | 0.4577±0.0069 |
| None | 0.5252±0.0200 | 0.7396±0.0106 | 0.4118±0.0173 | 0.6416±0.0137 | 0.4707±0.0096 |

Table 4. 14. LD50 task에 대한 Ablation Study 결과

MLP 모델에 BN, Dropout, WD 기법을 적용했을 때, 다양한 Task에서 전반적인 성능 향상이 관찰되었다. Solubility, CYP3A4 inhibitor, HLM, UGT substrate 특성들에서는 3가지 기

법을 모두 적용했을 때 가장 높은 성능을 보였다. 반면, 나머지 특성에서는 특정 기법을 제외한 조건에서 더 높은 성능이 나오는 경우가 존재하는 것을 확인할 수 있었다. 이는 Task에 따라서 최적의 구성 조건이 다름을 시사한다.

# V. 결　　론

## 5. 1. Proposed 모델과 Baseline 모델의 성능 비교

본 연구에서는 MLP와 RF 모델을 활용하여 ADMET 속성을 예측하고, 두 모델의 성능을 비교했다. 연구 결과, MLP는 대다수의 ADMET 속성 예측에서 RF보다 우수한 성능을 보였으나, 일부 Task에서는 RF와 비슷하거나 더 낮은 성능을 기록했다. 이러한 결과는 데이터 양의 한계로 인해 딥러닝 모델이 학습 과정에서 충분히 일반화된 패턴을 학습하지 못했기 때문으로 판단된다.

이러한 결과는 ADMET property 예측에서 데이터 수의 제약이 딥러닝 모델의 학습 능력을 제한할 수 있음을 시사한다. 이를 해결하기 위해, pre-training을 통해 분자 구조에 대한 일반화된 지식을 학습하는 방안을 고려할 수 있다. 대규모 화합물 데이터셋을 활용한 사전 학습을 수행한 후, 각 ADMET 속성에 대해 fine-tuning을 진행하면, 제한된 데이터 환경에서도 높은 예측 성능을 달성할 수 있을 것으로 기대된다.

데이터 양의 한계를 극복하기 위한 방법으로 데이터 Augmentation도 효과적일 것으로 생각한다. 예를 들어, 하나의 분자에 대해 canonical한 SMILES 문자열 한 가지 형태만 사용하는 대신, 화학적으로 유효한 모든 SMILES 표현식을 생성하는 방법 [19]이나, SMILES 문자열에 노이즈를 추가하여 데이터를 증강하는 방식 [20]을 적용할 수 있다. 이러한 데이터 증강 기법을 활용하려면 모델을 RNN 기반 또는 Transformer 기반으로 변경하여, SMILES 문자열을 입력으로 사용할 수 있도록 설계할 필요성이 있다.

## 5. 2. Random split과 Scaffold split 성능 비교

Scaffold split의 결과를 통해, 일부 예측 모델이 학습 데이터의 Morgan Fingerprint 내에서 Scaffold 패턴에 과도하게 의존하고 있음을 보여준다. 이는 모델이 학습에 사용되지 않은 Scaffold를 가진 분자에 대해 일반화 성능이 떨어지며, 신약 개발과 같은 실제 응용에서 모델의 활용이 제한적일 수 있음을 시사한다.

이 문제를 해결하기 위해서 분자의 구조 정보 외에도, 물리화학적 성질과 같은 추가적인 modality를 사용하여 학습하는 접근법을 고려할 수 있다. 이를 통해 모델이 특정 구조적 패턴에 과적합 되는 문제를 완화하고, 새로운 Scaffold를 가진 분자에 대한 예측 정확도를 향상시킬 수 있을 것으로 기대된다.

## 5. 3. Ablation Study

본 연구에서는 Batch Normalization(BN), Dropout, Weight Decay(WD)와 같은 정규화 기법이 ADMET 속성 예측에 미치는 영향을 분석하였다. 일부 Task에서는 이러한 기법을 제외한

경우 성능이 더 높게 나타났다. 이는 BN이 소규모 데이터셋에서의 분포 변화 과정이 부정적인 영향을 끼쳤을 가능성, WD가 중요한 파라미터를 과도하게 제약했을 가능성, 또는 Dropout이 학습의 안전성에 악영향을 주거나 정규화 효과가 과도하게 작용했을 가능성을 시사한다.

정규화 기법은 일반적으로 모델의 일반화 성능을 향상시키는 것으로 알려져 있으나, 본 연구는 특정 Task에서는 이러한 기법이 오히려 성능 저하를 초래할 수 있음을 보여준다. 이는 Task의 특성과 요구 사항을 고려하지 않고 동일한 정규화 설정을 모든 Task에 적용하는 접근은 한계를 가질 수 있음을 시사한다. 본 연구는 ADMET 속성 예측에서 정규화 기법의 적합성을 면밀히 검토하고, 특정 Task에 최적화된 모델링 접근법을 개발해야 함을 강조한다. 이러한 맞춤형 설계는 신약 개발과 같은 실제 응용에서 더 신뢰할 수 있는 예측 성능을 제공할 수 있을 것으로 기대된다.

# 참고문헌


1. L. Fu et al., “ADMETlab 3.0: an updated comprehensive online ADMET prediction platform enhanced with broader coverage, improved performance, API functionality and decision support,” Nucleic Acids Research, vol. 52, no. W1, pp. W422-W431, Apr. 2024, doi: 10.1093/nar/gkae236.
2. E. L. Cáceres, M. Tudor, and A. C. Cheng, “Deep learning approaches in predicting ADMET properties,” Future Medicinal Chemistry, vol. 12, no. 22, pp. 1995-1999, Oct. 2020, doi: 10.4155/fmc-2020-0259.
3. X. Liu, B. Testa, and A. Fahr, “Lipophilicity and Its Relationship with Passive Drug Permeation,” Pharmaceutical Research, vol. 28, no. 5, pp. 962-977, Oct. 2010, doi: 10.1007/s11095-010-0303-7.
4. M. C. Sorkun, A. Khetan, and S. Er, “AqSolDB, a curated reference set of aqueous solubility and 2D descriptors for a diverse set of compounds,” Scientific Data, vol. 6, no. 1, Aug. 2019, doi: 10.1038/s41597-019-0151-1.
5. T. Bohnert and L.-S. Gan, "Plasma protein binding: From discovery to development," Journal of Pharmaceutical Sciences, vol. 102, no. 9, pp. 2953-2994, 2013. DOI: 10.1002/jps.23614.
6. Z. Wu et al., “MoleculeNet: a benchmark for molecular machine learning,” Chemical Science, vol. 9, no. 2, pp. 513-530, Oct. 2017, doi: 10.1039/c7sc02664a.
7. H. Veith et al., “Comprehensive characterization of cytochrome P450 isozyme selectivity across chemical libraries,” Nature Biotechnology, vol. 27, no. 11, pp. 1050-1055, Oct. 2009, doi: 10.1038/nbt.1581.
8. L. Li, Z. Lu, G. Liu, Y. Tang, and W. Li, “In Silico prediction of human and rat liver microsomal stability via machine learning methods,” Chemical Research in Toxicology, vol. 35, no. 9, pp. 1614-1624, Sep. 2022, doi: 10.1021/acs.chemrestox.2c00207.
9. L. Di et al., "Mechanistic insights from comparing intrinsic clearance values between human liver microsomes and hepatocytes to guide drug design," European Journal of Medicinal Chemistry, vol. 57, pp. 441-448, 2012. DOI: 10.1016/j.ejmech.2012.06.043.
10. A. Karim, M. Lee, T. Balle, and A. Sattar, “CardioTox net: a robust predictor for

hERG channel blockade based on deep learning meta-feature ensembles," Journal of Cheminformatics, vol. 13, no. 1, Aug. 2021, doi: 10.1186/s13321-021-00541-z.

11. H. Zhu, T. M. Martin, L. Ye, A. Sedykh, D. M. Young, and A. Tropsha, "Quantitative Structure−Activity Relationship modeling of rat acute toxicity by oral exposure," Chemical Research in Toxicology, vol. 22, no. 12, pp. 1913-1921, Oct. 2009, doi: 10.1021/tx900189p.
12. J. Simm et al., "Splitting chemical structure data sets for federated privacy-preserving machine learning," Journal of Cheminformatics, vol. 13, no. 1, Dec. 2021, doi: 10.1186/s13321-021-00576-2.
13. Y. Hu, D. Stumpfe, and J. Bajorath, "Computational exploration of molecular scaffolds in medicinal chemistry," Journal of Medicinal Chemistry, vol. 59, no. 9, pp. 4062-4076, Feb. 2016, doi: 10.1021/acs.jmedchem.5b01746.
14. S. Ioffe and C. Szegedy, "Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift," International Conference on Machine Learning (ICML), 2015. Available: arXiv:1502.03167v3
15. N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A Simple Way to Prevent Neural Networks from Overfitting," Journal of Machine Learning Research, vol. 15, pp. 1929-1958, 2014. Available: http://www.jmlr.org/papers/v15/srivastava14a.html
16. I. Loshchilov and F. Hutter, "Decoupled Weight Decay Regularization," International Conference on Learning Representations (ICLR), 2019. Available: arXiv:1711.05101v3
17. F. Lombardo, G. Berellini, and R. S. Obach, "Trend analysis of a database of intravenous pharmacokinetic parameters in humans for 1352 drug compounds," Drug Metabolism and Disposition, vol. 46, no. 11, pp. 1466-1477, Nov. 2018. DOI: 10.1124/dmd.118.082966.
18. M. Huang et al., "In silico prediction of UGT-mediated metabolism in drug-like molecules via graph neural network," Journal of Cheminformatics, vol. 14, no. 1, Jul. 2022, doi: 10.1186/s13321-022-00626-3.
19. E. J. Bjerrum, "SMILES Enumeration as Data Augmentation for Neural Network Modeling of Molecules," arXiv preprint, arXiv:1703.07076, May 2017. Available: https://arxiv.org/abs/1703.07076.

20. J. Jiang, R. Zhang, Y. Yuan, T. Li, G. Li, Z. Zhao, and Z. Yu, "NoiseMol: A noise-robusted data augmentation via perturbing noise for molecular property prediction," Journal of Molecular Graphics and Modelling, vol. 121, no. 108454, 2023. DOI: 10.1016/j.jmgm.2023.108454.

# Acknowledgment

대학교에 입학하고, 졸업까지 긴 여정 동안, 많은 분들에게 도움이 없었다면 지금의 제가 있을 수 없었을 것입니다. 여러분의 도움 덕분에 학부 과정을 졸업하고, 대학원에서 새로운 여정을 시작할 수 있게 되었습니다. 이 자리를 빌려 학부 과정에서 저를 응원하고 격려해 주신 모든 분께 깊은 감사의 인사를 전합니다.

특히나 학부 과정 마지막 1년간 제 연구를 지도해 주신 남호정 교수님께 감사드립니다. 교수님의 지도 아래 연구자로서 한 단계 더 성장할 수 있었고, 대학원에서 더욱 깊이 있는 연구를 이어갈 수 있는 밑거름을 다질 수 있었습니다. 부족한 점이 여전히 많지만, 앞으로도 교수님께서 가르쳐 주신 것을 마음에 새기며 정진하겠습니다.

마지막으로 언제나 저를 사랑으로 응원해주는 가족들에게 감사의 말씀을 전합니다. 제 모든 도전과 선택을 지지해 준 가족들의 사랑이 있었기에 여기까지 올 수 있었습니다.